

Обучение машинного перевода без параллельных текстов*

Иванов А. В. Бахтеев¹ О. Ю. Стрижов² В. В.

ivanov.aleksandr@phystech.edu

¹Московский физико-технический институт

²Вычислительный центр им. А. А. Дородницына ФИЦ ИУ РАН

Большая часть моделей машинного обучения, используемых для перевода, в процессе обучения используют параллельные тексты на различных языках. В случае некоторых пар языков не удастся построить тренировочную выборку достаточного размера. Для решения этой проблемы были предложены способы тренировки моделей, основанные на автокодировщиках. Каждому предложению из обоих языков ставится в соответствие некоторый "смысловой" вектор в скрытом пространстве. Модель учится переводить предложения с одного языка на другой при попытках восстановления изначальных предложений по их скрытому представлению. В данной работе проводится исследование предложенного подхода для перевода между двумя близкими языками: русским и украинским. **Ключевые**

слова: перевод, автокодировщик.

Введение

Выбор модели машинного обучения, используемой для перевода, зависит от специфических особенностей пары языков. Так, использование глубоких нейронных сетей приводит к качественным результатам, но только в том случае, если количество параллельных предложений в обучающей выборке достаточно велико. Были достигнуты результаты уже для миллионной выборки. [1],[2].

В случае, когда размер обучающей выборки не достаточен, для ее пополнения может быть использован результат предыдущих итераций обучаемой нейронной сети. Данный результат представлен в [3].

Во многих работах представлено решение задачи машинного перевода в том случае, когда количества параллельных предложений не достаточно для обучения полноценного обучения глубокой сети [4], [5], [6]. В данном подходе используются 2 типа автокодировщиков. Первый - рекуррентные нейронные сети LSTM ([7]) используются для перевода слов изначального языка в скрытое векторное пространство. Второй - дискриминатор, восстанавливающий исходное предложение по скрытому внутреннему представлению, являющемуся результатом работы первой сети.

Оптимизация автокодировщиков производится таким образом, чтобы их результирующие представления совпадали. В некотором смысле, это означает искусственное создание проблемы для дискриминатора чтобы он не мог с достаточной точностью определить язык по скрытому представлению некоторого предложения. Для борьбы с переобучением добавляется шум, который не дает возможности абсолютно точного восстановления текста по его представлению после обработки автокодировщиком. Шаг оптимизации состоит из двух частей. Изначально выбирается случайное предложение из исходного языка и кодируется с добавлением шума [8]) после чего подаётся на вход дискриминатору. Далее аналогичные

действия повторяются со случайным предложением из второго языка. На второй стадии выбирается произвольное предложение из исходного языка, переводится текущей моделью на конечный язык. На результат накладывается шум, и для зашумленного предложения выполняется полный обратный перевод, после чего вычисляется функция потерь. Затем аналогичные действия проводятся с произвольно выбранным предложением конечного языка.

Для перевода с русского на французский языки и обратно такой подход был продемонстрирован в [9].

В качестве эксперимента производится перевод предложений с русского языка на украинский. Качество результата оценивается с помощью метрики BLEU [10].

Постановка задачи

Литература

- [1] Bilingual word embeddings for phrase-based machine translation / Will Y Zou, Richard Socher, Daniel Cer [и др.] // Proceedings of the 2013 Conference on Empirical Methods in Natural Language Processing. 2013. С. 1393–1398.
- [2] On the properties of neural machine translation: Encoder-decoder approaches / Kyunghyun Cho, Bart Van Merriënboer, Dzmitry Bahdanau [и др.] // arXiv preprint arXiv:1409.1259. 2014.
- [3] Bertoldi Nicola, Federico Marcello. Domain adaptation for statistical machine translation with monolingual resources // Proceedings of the fourth workshop on statistical machine translation / Association for Computational Linguistics. 2009. С. 182–189.
- [4] Google’s neural machine translation system: Bridging the gap between human and machine translation / Yonghui Wu, Mike Schuster, Zhifeng Chen [и др.] // arXiv preprint arXiv:1609.08144. 2016.
- [5] Sutskever Ilya, Vinyals Oriol, Le Quoc V. Sequence to sequence learning with neural networks // Advances in neural information processing systems. 2014. С. 3104–3112.
- [6] Bahdanau Dzmitry, Cho Kyunghyun, Bengio Yoshua. Neural machine translation by jointly learning to align and translate // arXiv preprint arXiv:1409.0473. 2014.
- [7] Graves Alex, Schmidhuber Jurgen. Framewise phoneme classification with bidirectional LSTM and other neural network architectures // Neural Networks. 2005. Т. 18, № 5-6. С. 602–610.
- [8] Kim Yunsu, Ney Jiahui Geng Hermann. Improving Unsupervised Word-by-Word Translation with Language Model and Denoising Autoencoder. 2018.
- [9] Lample Guillaume, Denoyer Ludovic, Ranzato Marc’Aurelio. Unsupervised machine translation using monolingual corpora only // arXiv preprint arXiv:1711.00043. 2017.
- [10] BLEU: a method for automatic evaluation of machine translation / Kishore Papineni, Salim Roukos, Todd Ward [и др.] // Proceedings of the 40th annual meeting on association for computational linguistics / Association for Computational Linguistics. 2002. С. 311–318.